



資料探勘： 日本城市人流特性分析與軌跡預測

第3組：高健壹、陳致瑋、劉子銘、黃楷奇、黃俊傑、陳旭霖



題目說明

日本城市人流特性分析與軌跡預測

以大規模去識別化移動軌跡資料為基礎，結合資料探勘技術與深度學習模型，分析城市人流的時空規律，並實現個人化移動軌跡的預測與生成。

資料來源

日本城市大規模去識別化智慧型手機移動軌跡資料集
provided by LY Corporation (previously Yahoo Japan)

核心目標

分析人流時空特性→預測並生成個人移動軌跡

背景動機 — 極端都市化帶來的挑戰

三大都市圈人口佔比

51.8%

過半人口集中於東京、大阪、名古屋

▶ 數據來源：日本總務省統計局《令和2年國勢調查》

東京圈淨遷入人數 (2023)


+11.4萬

全國人口連年負成長下，首都圈仍呈現單極集中現象。

▶ 數據來源：日本總務省《住民基本台帳人口移動報告》

日本城鄉人口推移與預測 (1980 - 2050)

來源：國土交通省《國土的長期展望》



引發的核心問題

- ✦ 通勤尖峰交通擁擠
- ✦ 突發事件疏散困難
- ✦ 觀光熱點乘載超載

背景動機 — 極端都市化帶來的挑戰

三大都市圈人口佔比

51.8%

過半人口集中於東京、大阪、名古屋

► 數據來源：日本總務省統計局《令和2年國勢調查》

東京圈淨遷入人數 (2023)

+11.4萬

全國人口連年負成長下，首都圈仍呈現單極集中現象。

► 數據來源：日本總務省《住民基本台帳人口移動報告》

日本城鄉人口推移與預測 (1980 - 2050)

來源：國土交通省《國土的長期展望》



引發的核心問題

- * 通勤尖峰交通癱瘓
- * 突發事件疏散困難
- * 觀光熱點乘載超載

背景動機 — 城市人流預測的必要性



防災與歸宅困難支援

首都直下型地震發生時，預估將產生**約517萬**歸宅困難者。預測人流可避免車站群聚踩踏，並優化避難所資源配置。

來源：內閣府防災會議



觀光公害 (Overtourism)

訪日遊客創歷史新高。京都等地急需預測景點未來擁擠度，以進行即時路線導引，平衡居民生活與觀光品質。

來源：觀光廳《觀光白皮書》



零售業動態營運

面對嚴重缺工，超商與零售業依賴預測商圈未來人流，進行**精準人力排班**與生鮮食品的廢棄減量管控。

來源：經濟產業省




公共交通彈性調度

大型活動(如祭典、演唱會)前後的突發性人潮預測，協助鐵道公司動態增加臨時班次，避免交通系統癱瘓。

來源：國土交通省

日本位置情報(LBS)相關市場規模預測


單位: 億日圓



▶ 數據來源參考：矢野經濟研究所《位置情報関連市場推移與預測》

背景動機 — 行動裝置與物聯網的普及

日本智慧型手機普及率 (2023)



► 數據來源：日本總務省《令和5年版 情報通信白書》
(註：涵蓋所有年齡層之平均值)

數據採集與分析視覺化流程



運作原理：透過超過 **1億台** 活躍的智慧型裝置，結合日本密集的 4G/5G 基地台與公共 Wi-Fi，持續產生海量數位足跡。經過嚴格的隱私去識別化處理後，成為訓練預測模型的絕佳養分。

資料集介紹 — 日本城市去識別化手機 GPS紀錄點



Raw Data

uid	d	t	x	y
1	1	1	38	96
1	1	1	39	97
1	3	3	14	94
1	3	3	15	82
1	3	3	23	80
1	3	3	24	81

...

1565	47	14	124	86
1565	47	15	125	86
1565	47	19	125	86
1565	47	23	123	86
1565	47	26	125	86
1565	47	27	125	86

Visualization





研究問題

問題 1

城市移動熱點如何分布？

在無預設分群的前提下，如何從原始軌跡資料中識別出具有意義的城市移動聚集區域

問題 2

不同地點的語意角色為何？

車站、學校、商店街等地點在工作日與假日呈現截然不同的人流特性，如何從資料中萃取這些語意標籤？

問題 3

個人移動軌跡是否可被預測與生成？


整合空間、語意與時序規律性特徵後，能否建立可依條件生成多樣化個人人流資料的生成模型？

本專案目的 — 城市人流的分析與預測

一般統計難以捕捉人群移動的複雜時空與語意特徵，因此我們採用多種資料探勘方式，結合條件式生成式模型，來預測並依據條件生成多樣個人人流數據。



資料前處理






空間處理

- 透過調整拉伸長/寬修正誤差，並利用 OpenStreetMap 進行還原。
- 將資料進行 8 種幾何轉換後，根據 Spearman 係數找出最符合的組合。



時間處理

- 利用 K-means 分群判斷平假日，再由國定假日或特殊事件(颱風、展覽)比對確切日期。
- 將一天切成 48 個時階段，以保留細節並去除多餘資訊。



預計資料探勘方法 — HDBSCAN



K-Means

需事先給定 K 值，且假設資料為球狀分佈，不符真實人流樣態。



DBSCAN

全局固定密度。無法同時處理「擁擠車站」與「稀疏郊區」。



HDBSCAN 突破

- ✓ 無須給定 K 值
- ✓ 自適應多變密度
- ✓ 高度抗噪過濾



HDBSCAN 四步演算法

1

相互可達距離

計算距離，將低密度雜訊推遠，凸顯真實熱點。

2

最小生成樹 (MST)

以距離為權重，建構連通所有點且總距離最短的樹狀圖。

3


層次聚類 (Hierarchy)

依序砍斷最長連線，形成階層式樹狀圖 (Dendrogram)。

4

萃取穩定群集


計算分支「穩定度 (Stability)」，自動選出最抗噪熱點。



預計資料探勘方法 — POI 分析



工作日與假日的人流分布相異，像是學校就工作日較多人、商店街就假日較多人。

此方法將利用不同時間點的人流資訊來區分網格。




預計資料探勘方法 一個人軌跡

1. 將特定時間、地點使用者分群如上下班時間的學校、車站、商店街等
2. 將每群依照時序繪製軌跡
3. 結果分析與預測



預計使用模型 — CVAE





預計成果 — 評估指標

GEO-BLEU

計算預測軌跡與實際軌跡的相似性

FDE

預測軌跡最後一個時間點的距離誤差





預計成果 — 目標

準確率

軌跡預測準確率超越資料集所提供的baseline

作息分析

依照各時段的軌跡分析使用者的作息

可解釋化

可解釋模型如何預測使用者的軌跡